CIÊNCIA DE DADOS TEÓRICA E APLICADA

Fundamentos de Modelos Lineares

Um guia didático e matematicamente rigoroso para iniciantes: da equação da reta ao formalismo matricial, equação normal, geometria de projeções e gradiente descendente.

1. A Grande Ideia: O que é um Modelo Linear?

Em Ciência de Dados, queremos descobrir como características de um objeto (como área, número de quartos ou localização) influenciam um resultado que queremos prever (como o preço de venda). O **modelo linear** é a forma mais simples e elegante de responder a isso: ele assume que o resultado final é simplesmente a soma ponderada de cada atributo multiplicado pela sua devida *importância* (chamada de **peso** ou parâmetro).

A Intuição Geométrica: A Reta

No ensino fundamental aprendemos a fórmula da reta: **y = ax + b**.

- **b (ou w_0)**: O ponto de partida (termo independente ou *bias/viés*). É o valor de y quando x vale zero.
- **a (ou w_1)**: A inclinação (coeficiente angular). Indica quantas unidades y sobe ou desce a cada 1 unidade de x adicionada.

O Exemplo Clássico dos Apartamentos

Imagine que temos duas amostras no mercado imobiliário:

- Apartamento 1: Área de **40 m²** custa **R$ 90.000**.
- Apartamento 2: Área de **100 m²** custa **R$ 150.000**.

Podemos montar o sistema de equações lineares:

$90.000 = w_1 \times 40 + w_0$

$150.000 = w_1 \times 100 + w_0$

2. Resolvendo o Sistema Exato (Cenário N = D)

Quando o número de imóveis observados (**N = 2**) é exatamente igual ao número de parâmetros a estimar (**D = 2**, sendo o viés e a inclinação), o sistema é *determinado* e possui solução exata sem erros:

Resolução Manual pelo Método da Substituição / Eliminação:

Subtraindo a primeira equação da segunda: $(150.000 - 90.000) = w_1 \times (100 - 40) \rightarrow 60.000 = w_1 \times 60 \rightarrow$ **w_1 = 1.000 R$/m²**.

Substituindo de volta na primeira: $90.000 = 1.000 \times 40 + w_0 \rightarrow 90.000 = 40.000 + w_0 \rightarrow$ **w_0 = 50.000 R$**.

Equação Prevista do Mercado: $Preço = 1.000 \times (Área) + 50.000$.

```
Para 70 m²:   Preço = 1.000 × (70) + 50.000 = R$ 120.000 (Sem erro: e = ŷ − y = 0)
```

Conceito Escolar	Termo em Ciência de Dados	Significado no Problema
Variável independente (x)	Atributo / Feature / Covariável	Área do apartamento (m²)
Variável dependente (y)	Alvo / Target / Rótulo / Resposta	Preço de venda real (R$)
Coeficiente angular (a)	Peso da característica (w_1)	Valorização por metro quadrado (R$ 1.000/m²)
Coeficiente linear (b)	Viés / Bias / Intercepto (w_0)	Custo fixo base do imóvel (R$ 50.000)

3. Fundamentos de Álgebra Linear para Ciência de Dados

No mundo real, não lidamos com apenas dois apartamentos e uma variável. Temos centenas de milhares de linhas e dezenas de colunas (área, quartos, banheiros, idade do prédio). Escrever fórmulas algébricas normais se torna impossível. Por isso, a Ciência de Dados utiliza **vetores e matrizes**.

O Produto Escalar (Dot Product): O Coração da Predição

O produto escalar entre o vetor de características de um objeto **x** e o vetor de pesos **w** expressa exatamente a soma ponderada de todas as influências:

$$\hat{y}_i = x_i^T w = \sum_{j=1}^{D} x_{ij} w_j = w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_D x_{iD}$$

4. A Estrutura Matricial Global: Xw = y

Empilhamos todos os **N** apartamentos em uma grande matriz de dados **X** (onde cada linha é um imóvel e a primeira coluna é preenchida com o número 1 para multiplicar o viés w_0):

$$[\ \hat{y}_1\ ;\ \hat{y}_2\ ;\ \dots\ ;\ \hat{y}_N\ ] = [\ 1\ \ x_{11}\ \ \dots\ \ x_{1D}\ ;\ \ 1\ \ x_{21}\ \ \dots\ \ x_{2D}\ ;\ \ \dots\ ;\ \ 1\ \ x_{N1}\ \ \dots\ \ x_{ND}\ ] \times [\ w_0\ ;\ w_1\ ;\ \dots\ ;\ w_D\ ]$$

Dimensões Envolvidas

- **X**: Matriz de dados de tamanho (N × D).
- **w**: Vetor coluna de pesos de tamanho (D × 1).
- **y**: Vetor coluna de respostas reais de tamanho (N × 1).
- **ŷ = Xw**: Previsões geradas pelo modelo.

Solução por Matriz Inversa (Gauss-Jordan)

Se **N = D** e as colunas de X forem linearmente independentes, a matriz X é quadrada e invertível (det(X) ≠ 0):

$$X\ w = y \ \Rightarrow\ X^{-1}\ X\ w = X^{-1}\ y \ \Rightarrow\ \mathbf{w^* = X^{-1}\ y}$$

5. O Dilema do Mundo Real: N ≫ D (Sistemas Sobredeterminados)

Em problemas reais de Ciência de Dados, temos milhares de apartamentos (ex: N = 10.000) e apenas algumas dezenas de colunas (D = 10). A matriz X é retangular vertical (muito mais linhas do que colunas).

O Problema da Impossibilidade da Inversa Direta:

Não existe inversa direta X^{-1} para matrizes não quadradas! Além disso, é humanamente impossível que uma única linha reta passe perfeitamente por 10.000 pontos dispersos na vida real (devido ao ruído e variações individuais). Portanto, **o erro não é mais zero: e = y − ŷ ≠ 0**. Nosso objetivo muda: já que não podemos zerar o erro, queremos encontrar o conjunto de pesos w que torne esse erro o menor possível!

6. Por que o Erro Médio Quadrático (MSE)?

Se medirmos os erros simples de cada apartamento $e_i = \hat{y}_i - y_i$, alguns serão positivos (previsão acima da realidade) e outros negativos (previsão abaixo). Se simplesmente somássemos os erros, eles se cancelariam (ex: +500 e −500 dariam soma zero, dando a falsa impressão de um modelo perfeito).

Vantagens Matemáticas do Quadrado

1. **Garante positividade:** $(e_i)^2$ é sempre maior ou igual a zero.
2. **Pune erros grotescos:** Errar por 10 custa 100; errar por 100 custa 10.000. O modelo aprende a evitar desvios aberrantes.
3. **Diferenciabilidade suave:** Permite calcular derivadas sem descontinuidades.

A Formulação Vetorial do Erro

O vetor de resíduos é $e = Xw - y$. A soma dos quadrados de seus elementos é calculada multiplicando o vetor por sua própria transposta (a norma euclidiana ao quadrado):

$$e^T e = \sum_{i=1}^{N} (e_i)^2 = ||Xw - y||_2^2$$

7. Dedução Algébrica Completa da Função de Custo E(w)

Expandindo a multiplicação vetorial do Erro Médio Quadrático termo a termo:

$$\begin{aligned} E(w) &= (1/N)\,(Xw - y)^T\,(Xw - y) \\ &= (1/N)\,(w^T X^T - y^T)\,(Xw - y) \\ &= (1/N)\,[\, w^T X^T X w - w^T X^T y - y^T X w + y^T y \,] \end{aligned}$$

Como $w^T X^T y$ é um escalar de dimensão (1 × 1), ele é idêntico à sua própria transposta: $(w^T X^T y)^T = y^T X w$. Assim, os dois termos do meio somam:

$$E(w) = (1/N)\,[\, w^T(X^T X)w - 2\, w^T(X^T y) + y^T y \,]$$

8. A Derivada Matricial e a Famosa Equação Normal

A função E(w) forma uma tigela convexa perfeita (um paraboloide). O ponto de menor erro possível (mínimo global) ocorre exatamente onde a inclinação da superfície se torna plana, ou seja, onde a **derivada do erro é igual a zero**:

Dedução da Solução Analítica Exata (Equação Normal):

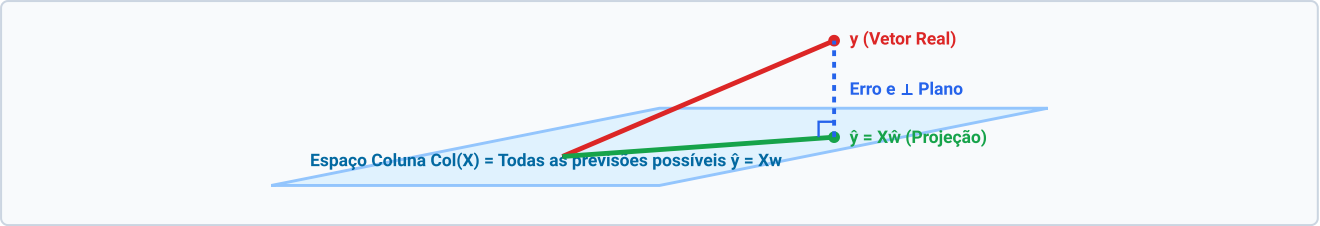
Aplicando as regras de derivadas matriciais conhecidas do caderno ($\partial(w^T A w)/\partial w = 2Aw$ e $\partial(w^T b)/\partial w = b$):

1. Derivada em relação a w: $dE(w) / dw = (2/N)\,[\, X^T X\, w - X^T y \,]$.
2. Igualando a derivada a zero: $(2/N)\,[\, X^T X\, \hat{w} - X^T y \,] = 0$.
3. Multiplicando ambos os lados por N/2: $X^T X\, \hat{w} - X^T y = 0 \;\Rightarrow\; (X^T X)\, \hat{w} = X^T y$.
4. Multiplicando pela inversa da matriz quadrada simétrica $(X^T X)^{-1}$:

$$\hat{w} = (X^T X)^{-1} X^T y$$

9. Visão Geométrica: Projeção Ortogonal no Hiperplano

Por que a fórmula $(X^TX)^{-1}\ X^Ty$ funciona tão perfeitamente? Geometricamente, o conjunto de todas as previsões possíveis que o modelo pode fazer $\hat{y} = Xw$ forma um subespaço (um plano) gerado pelas colunas da matriz X. O vetor com as respostas reais do mundo **y** geralmente está fora desse plano.



A menor distância física entre o vetor real **y** e o plano das previsões é dada pelo segmento de reta que forma **90 graus (ortogonal)** com o plano! Portanto, o vetor de erro $e = y - Xw$ deve ser perpendicular a todas as colunas de X:

$$X^T e = 0 \Rightarrow X^T (y - Xw) = 0 \Rightarrow X^Ty - X^TXw = 0 \Rightarrow \hat{w} = (X^TX)^{-1} X^Ty$$

10. O Limite da Equação Normal & O Gradiente Descendente

Se a Equação Normal é uma fórmula exata e analítica, por que não a usamos sempre? A resposta é: **custo computacional e memória em Big Data**.

O Gargalo da Inversão de Matriz

Inverter uma matriz de dimensão (D × D) tem complexidade de **O(D^3)**. Se tivermos 100.000 variáveis preditoras (como em processamento de texto ou genômica), o computador travará por falta de memória RAM ao tentar calcular $(X^TX)^{-1}$.

A Solução: Gradiente Descendente

Em vez de calcular o resultado de uma só vez, damos passos iterativos descendo a curva da tigela de erro. A cada iteração **t**, atualizamos os pesos dando um passo proporcional à inclinação do erro com uma **Taxa de Aprendizagem (η ou λ)**:

$$w^{[t+1]} = w^{[t]} - \eta\ \nabla E(w)$$

A Importância da Normalização das Features (X):

Se uma coluna mede renda (ex: 5.000) e outra mede quartos (ex: 2), a tigela da função de erro fica deformada e ovalada (muito estreita em uma direção). O gradiente fica ziguezagueando e demora a convergir. Normalizando os dados (Z-Score ou Min-Max), a tigela fica redonda e o gradiente desce reto ao alvo.

11. O Perceptron Learning Algorithm (PLA): Classificação Linear

Modelos lineares também servem para classificação binária (separar classes por uma linha reta divisória). O **Perceptron** proposto por Frank Rosenblatt aprende ajustando os pesos a cada erro de classificação cometido sobre uma amostra:

Função de Decisão do PLA

A previsão é dada pela função sinal:

$$\hat{y} = \text{sign}(w^T x) = \{ +1 \text{ se } w^T x \geq 0 \; ; \; -1 \text{ se } w^T x < 0 \}$$

O hiperplano de separação ocorre exatamente na fronteira $w^T x = 0$.

Regra de Atualização do PLA

Se o modelo errar a classe do ponto x_i (isto é, $\hat{y}_i \neq y_i$), o vetor de pesos é corrigido empurrando a reta na direção do ponto:

$$w^{[t+1]} = w^{[t]} + \eta \, y_i \, x_i$$

12. Generalização: Overfitting, Underfitting e Validação

Como visto nas anotações de aula do seu caderno, o maior perigo em Ciência de Dados não é errar no treino, mas memorizar o ruído dos dados e falhar em dados futuros desconhecidos (*Generalização*):

Os Três Regimes de Aprendizado

- **Subajuste (Underfitting):** O modelo é simples demais para captar o padrão real (erro alto tanto no treino quanto no teste).
- **Ajuste Ideal (Fitted):** O modelo captura a tendência verdadeira e generaliza com sucesso para novos dados.
- **Sobreajuste (Overfitting):** O modelo tenta se acomodar tão perfeitamente aos dados de treino que decora o ruído amostral. O erro de treino vai a zero, mas o erro de validação explode!

13. Soluções: Validação Cruzada & Regularização (Ridge / Lasso)

Para impedir que os pesos **w** cresçam descontroladamente para decorar cada ponto de treino, adicionamos uma **penalidade de complexidade Ω(w)** à função de erro:

A Equação de Regularização Geral:

$$E_{regularizado}(w) = E_{treino}(w) + \lambda \, \Omega(w)$$

O hiperparâmetro **λ** funciona como um botão de freio: se λ for grande, ele força os pesos a ficarem pequenos e comportados, prevenindo o overfitting e estabilizando a variância do modelo.

Técnica	Penalidade Matemática Ω(w)	Efeito Prático nos Pesos
Regressão Ridge (L2)	$\|\|w\|\|_2^2 = \sum w_j^2$	Encolhe todos os pesos uniformemente para perto de zero, mantendo todos os atributos ativos.
Regressão Lasso (L1)	$\|\|w\|\|_1 = \sum \|w_j\|$	Zera completamente os pesos de variáveis inúteis, agindo como um seletor automático de atributos.
Elastic Net	Combinação Linear: α L1 + (1 − α) L2	Combina o encolhimento estável da Ridge com a seleção de features esparsa do Lasso.

14. Exemplo Numérico Resolvido na Ponta do Lápis

Vamos executar o cálculo matricial exato da Equação Normal para encontrar a reta ideal de uma base com 3 apartamentos:

Dados dos Imóveis (Área x em dezenas de m², Preço y em milhares de R$):

- Casa 1: Área x = 1 (10 m²), Preço y = 2 (R$ 20.000)
- Casa 2: Área x = 2 (20 m²), Preço y = 3 (R$ 30.000)
- Casa 3: Área x = 3 (30 m²), Preço y = 5 (R$ 50.000)

Matriz **X** (com coluna de bias 1) e Vetor **y**:

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \qquad y = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix}$$

Resolução Passo a Passo:

1. **Multiplicação X^TX (Matriz 2 × 2):**
   - $X^TX = \begin{bmatrix} 1+1+1 & 1+2+3 \\ 1+2+3 & 1^2+2^2+3^2 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$
2. **Inversão de (X^TX):**
   - Determinante: det = (3 × 14) − (6 × 6) = 42 − 36 = 6.
   - Inversa: $(X^TX)^{-1} = (1/6) \times \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix} = \begin{bmatrix} 7/3 & -1 \\ -1 & 1/2 \end{bmatrix}$
3. **Multiplicação X^Ty (Vetor 2 × 1):**
   - $X^Ty = \begin{bmatrix} 2+3+5 \\ (1\times2)+(2\times3)+(3\times5) \end{bmatrix} = \begin{bmatrix} 10 \\ 23 \end{bmatrix}$
4. **Cálculo Final dos Pesos $\hat{w} = (X^TX)^{-1} X^Ty$:**
   - w_0 (viés) = (7/3)×10 + (−1)×23 = 70/3 − 69/3 = **1/3 ≈ 0.33**
   - w_1 (área) = (−1)×10 + (1/2)×23 = −10 + 11.5 = **1.5**

Reta Ótima Encontrada: `Preço = 1.5 × (Área) + 0.33`.

15. Os Quatro Pilares da Disciplina

Como registrado na primeira página do seu caderno de aula, o domínio de modelos em Ciência de Dados se sustenta sobre quatro fundamentos interligados:

Álgebra Linear & Métodos Numéricos

Estruturam os dados em matrizes e vetores, permitindo manipular espaços multidimensionais e controlar a estabilidade numérica contra erros de ponto flutuante.

Cálculo & Estatística/Probabilidade

O cálculo fornece as derivadas e gradientes que guiam a otimização dos modelos; a probabilidade modela a incerteza e os ruídos inerentes ao mundo real.

Conclusão Integrada

O modelo linear é o alicerce fundamental de toda a inteligência artificial moderna. Compreender a transição entre sistemas analíticos determinados (Gauss-Jordan), otimização por projeção ortogonal (Equação Normal) e convergência iterativa (Gradiente Descendente) é a chave para dominar desde simples previsões numéricas até redes neurais profundas.